



iQ-Foundry 課程講義

黃誌祥 | 智能周邊應用事業處 軟體研發部 副理 · 2026-07-30

AGENDA

- 實作里程碑
- iQ-Foundry 定位
- 實作流程說明
- 動手做

iQ9 實作演練 · 下半場 · iQ-Foundry

上半場你跑的是官方模型。

現在，把你自己的 **YOLO 26** 跑上 NPU。

取得模型 → 優化轉換 → 部署 PoC → 驗證。

全程動手

Bring Your Own Model

四個里程碑，全程動手

里程碑

1



取得模型



高通模型下載

YOLO 26 : Ultralytics 預訓練 / AI Hub / 自訓練 .pt。

2



優化轉換



QC / API Export

量化編譯成可在 NPU 跑的 INT8 模型。

3



部署 PoC



test · 實機

部署上機跑推論，送進 Streampipe。

4



驗證



mAP

mAP@0.5 對比 FP vs INT8，自己驗精度。

WHAT IS...

iQ-Foundry 定位

一條 **BYO-Model** 流水線。

把你自己的模型，量化 → 驗證 → 部署自動化。模型自主權始終在你手上；Apache-2.0。

HOST**x86**

Ubuntu 22.04 / WSL2 · 建議 ≥16GB RAM。

TARGET**On-device**


EXEC-Q911 (QCS9075) · 推論在 Hexagon NPU。

兩條轉換路徑**兩者都教**

iQ Foundry QC Mode / AI Hub API Export。

WORKFLOW: 今天下半場這條路

從你的模型，到 NPU 上的 PoC。



主機環境 (WSL2/Docker) → 取得模型 (Ultralytics / AI Hub → YOLO 26) → Model Conversion (QC Mode / AI Hub API Export) → StreamPipe (CH:9 / USB Camera / PPE APP)。

Host · 主機環境

● 動手

WSL2 + Docker · 裝好 iQ-Foundry。

```
$ # PowerShell(管理員): cd ~ ; git clone .../iQ-Foundry.git ; cd iQ-Foundry
$ powershell -ExecutionPolicy Bypass -File .\setup-windows-wsl.ps1
$ # ↓ 以下在 WSL 終端機 ( Docker 指令不在 PowerShell )
$ bash ./docker_install.sh
$ docker pull innodiskorg/iqf:latest
$ ./qaihub_login.sh --key <YOUR_QAI_HUB_API_KEY>
```

每人需自備 **Qualcomm AI Hub 帳號與 API token** (qc 雲端編譯需要) 。

Model · 取得模型 (高通模型下載)

[● 動手](#)

YOLO 26，三種來源。

Ultralytics

下載官方預訓練權重 .pt。

預訓練

Qualcomm AI Hub


從 AI Hub 取得模型。

高通

自訓練

你自己訓練的 .pt 直接帶進來。

.pt



截取時間: 2026-07-28

Convert · 路徑 A : AI Hub Export

● 動手

.tflite(FP32) → FP32 Running on NPU

```
$ python -m qai_hub_models.models.yolo26_det.export \  
--target-runtime tflite --precision float \  
--device "Dragonwing IQ-9075 EVK" --skip-profiling --skip-inferencing \  
--output-dir /ws/out_fp32
```

驗收 產出 /ws/out_fp32/yolov26.tflite (經 QAI Hub 雲端編譯) 。

YOLO26-Detection

Real-time object detection optimized for mobile and edge by Ultralytics.

Ultralytics YOLO26 is a machine learning model that predicts bounding boxes and classes of objects in an image.

Note: YOLO26-Detection cannot be downloaded directly due to licensing restrictions. You can export a model ready for on-device deployment using the AI Hub service.

[Export with Workbench](#)



float

tfLite

ws876

YOLO26-Detection

Dragonwing IQ-9075 EVK: Qualcomm® Dragonwing™ IQ-9075

REFERENCE TIME	THROUGHPUT	MEMORY USAGE	LAYERS
6.77 ms	295 max 148 single inferences / s	0 - 20 MB	398 NPU

Accuracy Metrics

REFERENCE METRIC
47.8 mAP@0.5:0.95
ON-DEVICE METRIC
47.6 mAP@0.5:0.95 (Dragonwing IQ-9075)

[See more metrics](#)

Convert · 路徑 B : iQ Foundry QC Mode


● 動手

.pt(FP32) → 全 INT8 .tflite。

```
$ ./docker/iqf run qc --type yolov26 --model yolov26n.pt --calib_dir calib/
```

選項：--max_calib(200) / --qc-quant-scheme mse|minmax / --qc-head one2many|one2one

驗收 產出 out/model/yolov26/yolov26_int8_<ts>.tflite (經 QAI Hub 雲端編譯)。




Convert · 路徑 C : Non-YOLO AI Hub API Export

非支援模型，也能上 NPU。

不在 yolov10/11/26 內的視覺模型：自走 ONNX → [Qualcomm AI Hub Workbench](#) (compile / quantize / inference)。

非 YOLO 的第二種轉法，是 QC 接不到時的逃生路徑。




Deploy · 模型轉換與部署 AI PoC

● 動手

轉好的模型，不管是INT8或是FP32，上機跑。

```
$ iqs-launcher --autotag iqs-streampipe --other "-c yolo26_int8.config" # 多路串流
```

轉好模型 → StreamPipe config → CH:9 · USB · PPE



驗收 模型在 EXMP-Q911 上跑出推論

(TFLite + QNN/HTP → Hexagon NPU) 。


Validate · 驗證 (mAP@0.5)

● 動手

量化掉多少精度？你自己驗。

```
$ ./docker/iqf run mAP --type yolov26 --fp-model yolov26n.pt \  
--int-model int8.tflite --annotations val.json --images val --max-images 5
```

```
adb shell 'rm -rf /data/local/tmp/yolo_map_eval/map_run_183661_1774235774598'  
FP vs INT mAP@0.5 Pair Evaluation  
model_type: yolov26  
fp_head: one2many  
annotations: /home/sanoop/Projects/yolo11_det/coco/annotations/instances_val2017  
images: /home/sanoop/Projects/yolo11_det/coco/val2017  
num_images: 300  
fp_model: /home/sanoop/Projects/qai_hub_conv_pipeline/mAP_eval_models/yolov26n.pt  
int_model: /home/sanoop/Projects/qai_hub_conv_pipeline/mAP_eval_models/int8.tflite  
fp_map50: 0.523173  
int_map50: 0.511969  
abs_delta_int_minus_fp: -0.011204  
pct_delta_vs_fp: -2.14%  
trend: decrease
```



```
[ok] wrote: /home/sanoop/workspace/iq-Studio/tutorials/model-pipeline/cv/yolo/out/mAP_results/yolov26/yolov26_mAP_result_20260323_111612.txt
```

The Relay · 看到 → 擁有

取模 → 轉換 → 部署 → 驗證

一條可重複、可驗證的路。模型自主權，回到你手上。

iQ-Studio

→

iQ-Foundry

看到 · 系統能跑

擁有 · 跑你自己的

Simplify the Workflow, Accelerate Deployment.



innodisk

**ARCHITECT
INTELLIGENCE**



```
Terminal
root@exmp-q911:~# genieX infer unsloth/Qwen3-30B-A3B-GGUF --compute cpu --think=false
> [end a message (/? for help)]
```

Developer Preview

Qualcomm AI Hub Models

Community GGUF Models

GenieX

Run Any Gen AI Model On Device

Star on GitHub 8K

NPU GPU CPU

702 system / 20 0 222M 3572 3204 S 0.0 0.0 0:00.01 /usr/bin/adsp
F1Help F2Setup F3Search F4Filter F5Tree F6SortBy F7Nice F8Nice F9Kill F10Quit